# OncoLien : colonnes à garder et à retirer

Prédiction de l'aggravation à 7 jours avec un modèle de machine learning classique (XGBoost)

## Ce qu'il faut prédire

**Cible : aggravation_7j.** Elle vaut 1 si le patient atteint un grade rouge confirmé, ou va aux urgences, ou est hospitalisé entre D+1 et D+7. Elle vaut 0 sinon. C'est une classification binaire : le modèle sort une probabilité, et vous fixez le seuil d'alerte. La cible est rare (environ 11,8 % de 1), donc évaluez avec PR-AUC, rappel et précision, pas avec l'accuracy.

**Règle de tri :** on ne garde que ce que l'application pourra réellement collecter, et rien qui soit une conséquence de l'état ou une cible. Le chat n'existe pas encore : toute colonne qui en dépend est retirée.

**Attention :** le fichier est simulé. Seuls les 12 symptômes du jour 1 et les colonnes d'origine de la feuille Patients sont réels. Ce tri sert à valider la chaîne technique, pas à tirer une conclusion clinique.

# PARTIE A. Feuille Suivi_quotidien (une ligne par patient et par jour)

## A1. À GARDER comme entrées du modèle

Ces colonnes sont saisies par le patient ou connues du système. Calculez aussi leurs tendances par patient (moyenne sur 3 et 7 jours, écart par rapport à la veille).

| Colonne | Pourquoi |
|---|---|
| **niveau_fatigue, nausee_vomissement, niveau_appetit, douleurs_dyspnee_insomnies, niveau_diarrhees, niveau_constipation** | Symptômes saisis chaque jour par le patient. Ce sont le signal principal. Leur tendance (fatigue qui monte sur plusieurs jours) annonce l'aggravation. |
| **capacite_physique, capacite_travail_loisirs, etat_emotionnel, capacite_cognitive, capacite_sociale** | Capacités et moral déclarés par le patient. Une baisse progressive précède souvent un problème. |
| **chute_cheveux** | Garder, mais signal faible : elle augmente lentement sous chimiothérapie et dit peu de choses à 7 jours. |
| **temperature_c** | Une fièvre (38 °C ou plus) est plus probable 1 à 2 jours avant une aggravation. Chez un patient sous chimiothérapie, c'est un signal d'alerte majeur. |
| **traitement_pris** | 1 = médicament pris, 0 = non pris. Un médicament non pris révèle un problème. Le 0 est ambigu (il vaut aussi 0 pendant une hospitalisation) : utilisez plutôt des versions passées (nombre de non-prises sur 3 jours). Vide = fiche non remplie. |
| **questionnaire_rempli** | Ne pas remplir sa fiche est un signal : le patient se tait souvent dans les 2 à 3 jours qui précèdent l'aggravation. Calculez le nombre de jours sans réponse. |
| **jour_dans_cycle, jours_depuis_derniere_dose, nb_cycles_recus** | Situent le patient dans son cycle de chimiothérapie. Le risque d'infection est maximal 1 à 2 semaines après une dose (creux vers le jour 10 d'un cycle de 21 jours). Vides hors chimiothérapie : ajoutez une colonne sous_chimio. |
| **globules_blancs_giga_l** | Entrée forte. Une baisse (neutropénie) rend une fièvre dangereuse. Mesurée chaque semaine : reportez la dernière valeur connue (forward fill par patient, jamais en arrière) et ajoutez le nombre de jours depuis la mesure. Utile seulement si l'application peut récupérer les prises de sang. |
| **hemoglobine_g_dl** | Entrée conditionnelle. Une baisse signale l'anémie (fatigue, essoufflement), mais le lien direct avec l'aggravation à 7 jours est plus faible. Même traitement des valeurs manquantes que les globules blancs. |

## A2. À GARDER SEULEMENT SOUS FORME PASSÉE (optionnelles)

Ces colonnes sont calculées à partir du jour même. Utilisez uniquement des versions décalées (jours précédents).

| Colonne | Pourquoi |
|---|---|
| **grade_jour** | Résumé du jour (0 vert, 1 orange, 2 rouge) calculé à partir des symptômes et de la température. Redondant avec les symptômes. Utile surtout en tendance (grades des 3 derniers jours). |
| **alerte_confirmee_infirmiere** | Sert à fabriquer la cible. Le jour même, c'est une conséquence. Utilisable seulement sous forme passée, par exemple « une alerte dans les 3 derniers jours ». |

## A3. COLONNES TECHNIQUES (pour préparer les données, pas pour entraîner)

À conserver dans le fichier mais à retirer de la matrice d'entrée X.

| Colonne | Pourquoi |
|---|---|
| **id_patient** | Sert à regrouper (calcul des tendances) et à découper train/test par patient (GroupKFold). Jamais une entrée : le modèle mémoriserait des patients au lieu d'apprendre des signes d'aggravation. |
| **date** | Sert à trier chaque patient dans l'ordre chronologique avant de calculer les tendances. Pas une entrée. |
| **eligible_entrainement** | Filtre : garde les lignes où la cible est connue, la fiche remplie et le patient pas déjà en rouge (environ 8 869 lignes). Appliquez-le puis retirez-le. |

## A4. CIBLE

Ce que le modèle doit prédire.

| Colonne | Pourquoi |
|---|---|
| **aggravation_7j** | Cible principale : 1 si un grade rouge confirmé, un passage aux urgences ou une hospitalisation survient entre D+1 et D+7. Vide pour les 7 derniers jours de chaque patient (futur inconnu), d'où le filtre eligible_entrainement. |

## A5. À RETIRER

Ces colonnes fausseraient le modèle ou ne pourront pas être collectées.

| Colonne | Pourquoi |
|---|---|
| **utilisation_chat** | Le chat n'existe pas encore : aucune donnée réelle ne pourra alimenter cette colonne. Elle est reliée à l'aggravation uniquement par les règles de simulation, donc le modèle apprendrait une relation inventée. À ajouter plus tard, avec de vraies données. |
| **appel_infirmiere** | Conséquence de l'état (100 % des jours rouges, 70 % des orange, 2 % des autres). Le modèle apprendrait « appel = problème », mais on veut prédire avant l'appel. De plus, l'appel peut éviter l'aggravation qu'on cherche à prédire. Fuite d'information. |
| **urgence_ou_hospitalisation (du jour même)** | Événement qui sert à fabriquer la cible. L'utiliser comme entrée revient à donner la réponse au modèle. |
| **grade_rouge_7j** | Cible intermédiaire. Circulaire, car le grade vient des règles du moteur et non d'une mesure médicale. Fait partie de la définition de aggravation_7j. |
| **urgence_ou_hospitalisation_7j** | Autre cible, la plus objective mais rare (2 %). Fait partie de la définition de aggravation_7j. À ne jamais mettre dans X. |
| **jour_suivi** | Numéro du jour (1 à 42) : artefact du fichier simulé. Dans la vraie vie, il n'a pas de signification stable pour prédire un risque. |

# PARTIE B. Feuille Patients (une ligne par patient)

Ces colonnes décrivent le risque de départ du patient. Elles sont saisies à l'inscription. On les rattache à chaque ligne de suivi par id_patient.

## B1. À GARDER comme entrées du modèle

Fixes dans le temps, elles donnent le contexte de risque.

| Colonne | Pourquoi |
|---|---|
| **age** | Le risque de complications augmente avec l'âge. |
| **metastase** | Maladie avancée, donc risque plus élevé. Entrée forte. |
| **traitements** | À découper en 4 colonnes (chimiothérapie, radiothérapie, hormonothérapie, chirurgie). La chimiothérapie est le facteur de risque principal (infections, creux du cycle). |
| **duree_maladie** | Contexte de gravité. Le texte (« 3 ans ») est à convertir en nombre. |
| **hta, diabete, anemie_connue, vih, n_comorbidites** | Les maladies associées augmentent le risque de complications. n_comorbidites résume leur nombre. |
| **ecog_etat_general** | Score d'état général du patient : plus il est dégradé, plus le risque est élevé. |
| **ligne_traitement** | Plus la ligne de traitement est avancée, plus la maladie est avancée. |
| **antecedent_urgences, antecedent_hospitalisation** | Un patient déjà passé aux urgences ou hospitalisé y retourne plus souvent. |
| **duree_cycle_jours, nb_cycles_avant_suivi** | Donnent le rythme du cycle de chimiothérapie (14, 21 ou 28 jours) et le nombre de cycles déjà reçus. À combiner avec jour_dans_cycle. |

## B2. OPTIONNELLES (à tester, sans lien fort attendu)

Garder au début seulement si vous voulez vérifier qu'elles n'apportent rien.

| Colonne | Pourquoi |
|---|---|
| **sexe** | Seulement 19 hommes sur 305. Sert surtout au niveau normal d'hémoglobine. |
| **poids_debut_kg** | Contexte général ; une perte de poids serait plus informative que le poids de départ. |
| **technique_chir, plan_traitement** | Faible utilité à 7 jours. À nettoyer : ajouter « aucune » pour les non-opérés, fusionner « oncologie » et « oncologique ». |
| **distance_hopital_km** | Pourrait influencer le recours aux urgences, mais sans lien programmé dans la simulation. |

## B3. COLONNES TECHNIQUES

Pour préparer les données.

| Colonne | Pourquoi |
|---|---|
| **id_patient** | Clé de jointure avec Suivi_quotidien et de découpage train/test par patient. |
| **date_debut_suivi** | Permet de trier dans le temps ou de couper entraînement/test par date. Pas une entrée. |

## B4. À RETIRER

Sans information utile ou conséquence du résultat.

| Colonne | Pourquoi |
|---|---|
| **id_ligne_origine** | Ancien numéro de ligne du fichier d'origine, sans signification médicale. Un modèle pourrait s'en servir à tort. |
| **type_cancer** | « Sein » pour les 305 patients : aucune information (constante). |
| **statut_vital** | C'est un résultat (survie), pas une information connue au départ. Fuite d'information. |
| **profession** | 25 valeurs pour 305 patients : surtout du bruit. À regrouper ou ignorer. |
| **fumeur, alcoolique** | Effets surtout à long terme, peu utiles pour une alerte à 7 jours. |
| **niveau_AP_avant, pratique_AP, debut_AP, type_exercices** | Utiles pour l'étude sur l'activité physique, pas pour l'alerte précoce. type_exercices a 61 formulations et beaucoup de cases vides. |

# PARTIE C. Schéma de préparation

1. Trier par id_patient puis date, calculer les tendances par patient (groupby).
2. Joindre la feuille Patients sur id_patient.
3. Filtrer eligible_entrainement == 1.
4. Définir y = aggravation_7j et les groupes = id_patient.
5. Construire X en retirant : id_patient, date, date_debut_suivi, eligible_entrainement, toutes les cibles et toutes les colonnes de la liste « À retirer ».
6. Découper par patient (GroupShuffleSplit ou GroupKFold), corriger le déséquilibre (scale_pos_weight), évaluer avec PR-AUC, rappel et précision.