OncoLien — Logique d'augmentation des données

et utilité de chaque colonne pour la prédiction de l'aggravation à 7 jours

Attention : les données ajoutées sont simulées. Elles servent à tester la chaîne technique d'OncoLien (calcul des variables, découpage, modèle de démonstration). Seules les colonnes d'origine de l'onglet Patients et les 12 symptômes du jour 1 sont réels. Un modèle entraîné sur ce fichier apprendrait les règles de la simulation, pas la réalité : aucune conclusion clinique n'est possible.

Fichier concerné : OncoLien_dataset_complet_simule.xlsx (305 patients, 42 jours de suivi chacun, 12 810 lignes).

1. Pourquoi augmenter les données

Le fichier d'origine contient une seule ligne par patient, avec des mesures prises à un moment donné. Pour prédire une aggravation dans les 7 jours qui suivent, il manquait trois choses :

- **Le temps :** une tendance (la fatigue qui monte doucement) ne se voit qu'avec plusieurs jours de suite. *Analogie : une seule photo ne dit pas si une voiture accélère ou freine.*
- **Une cible :** aucune colonne ne disait si le patient s'était aggravé ensuite. Le **statut_vital** mesure la survie, pas l'alerte précoce visée par OncoLien.
- **Le contexte du traitement et du suivi :** position dans le cycle de chimiothérapie, fièvre, prises de sang, comorbidités, antécédents, observance.

L'augmentation a donc consisté à **transformer chaque patient en un film de 42 jours dont la première image est sa ligne d'origine**, puis à ajouter les colonnes manquantes.

2. La logique, étape par étape

Étape 1 — Ancrer le jour 1 sur le réel

Pour chaque patient, le jour 1 reprend exactement les 12 symptômes et capacités du fichier d'origine (vérifié ligne par ligne). Les 41 jours suivants sont générés à partir de ces valeurs. Un patient très fatigué au départ reste donc plutôt fatigué ensuite.

Étape 2 — Faire évoluer une « gravité cachée »

Chaque jour, une gravité invisible monte ou descend. Elle combine : (a) le creux du cycle de chimiothérapie, avec un maximum vers le jour 10 d'un cycle de 21 jours (moins marqué pour les cycles de 14 ou 28 jours) ; (b) un petit bruit qui se prolonge d'un jour à l'autre ; (c) de rares pics passagers chez environ un patient sur quatre, qui jouent les fausses alertes. *Analogie : la météo du corps, dont chaque symptôme est un thermomètre différent.*

Étape 3 — Déduire chaque symptôme de cette gravité

Chaque symptôme réagit avec son propre poids : fatigue 1,1 ; nausées 1,0 ; appétit et douleurs 0,9 ; diarrhée 0,8 ; capacités physique et de travail 0,6 ; moral et capacité sociale 0,5 ; constipation 0,4 ; capacité cognitive 0,3 ; chute de cheveux 0,1 (elle augmente surtout lentement sous chimiothérapie). Les symptômes « plus haut = mieux » (fatigue, appétit, capacités, moral) baissent quand la gravité monte, les autres montent. Ce sens est déduit des données, où les deux groupes sont corrélés négativement : il reste à confirmer. Un bruit quotidien est ajouté, puis les valeurs sont arrondies et bornées entre 1 et 10.

Étape 4 — Programmer les aggravations

Environ 22 % des patients (68 sur 305) ont une aggravation. Leur probabilité augmente avec la chimiothérapie, les métastases, l'âge, la présence d'une comorbidité, un antécédent d'urgences et des symptômes élevés au départ. Elle survient plutôt autour du creux du cycle. Avant l'événement, la gravité monte sur 3 à 6 jours : c'est la tendance que le modèle doit apprendre à repérer. Dans 20 % des cas, la montée est brutale (1 jour) et donc presque imprévisible : tout n'est volontairement pas détectable. Environ 60 % de ces aggravations (42 sur 68) donnent un passage aux urgences ou une hospitalisation, suivie de 3 jours sans réponse.

Étape 5 — Ajouter les comportements et les mesures

Fièvre : température normale autour de 36,7 °C ; une fièvre à 38 °C ou plus est rare, mais plus probable 1 à 2 jours avant une aggravation. **Silence :** le patient remplit sa fiche environ 9 jours sur 10, moins quand il va mal et souvent pas dans les 2 à 3 jours qui précèdent l'aggravation. **Observance et chat :** légèrement dégradés quand l'état se dégrade. **Prises de sang :** chaque semaine pour les patients sous chimiothérapie ; les globules blancs baissent au creux du cycle et avant une aggravation.

Étape 6 — Créer les colonnes fixes manquantes

Comorbidités (hypertension et diabète augmentent avec l'âge ; anémie 12 % ; VIH 4 %), état général déduit de la capacité physique, ligne de traitement (plus avancée si métastases), antécédents d'urgences et d'hospitalisation (plus probables si métastases, comorbidités ou état général dégradé), distance à l'hôpital, poids de départ, durée du cycle et nombre de cycles déjà reçus.

Étape 7 — Calculer les grades et les cibles comme le ferait l'application

Un moteur de règles provisoire attribue chaque jour un grade 0 (vert), 1 (orange) ou 2 (rouge) : rouge si la température atteint 38 °C ou si la gravité moyenne des 6 symptômes principaux atteint 8,5 ; orange à partir de 37,5 °C ou de 6,75. Ces seuils sont calibrés sur ce fichier pour obtenir environ 71 % de jours verts, 22 % orange et 6 % rouge : ils ne sont pas cliniques. Les cibles regardent ensuite les 7 jours suivants (D+1 à D+7) et sont vides pour les 7 derniers jours de chaque patient.

Chiffres clés du jeu de données obtenu

Mesure	Valeur
Patients / jours de suivi / lignes	305 / 42 / 12 810
Patients avec une aggravation	68 (22 %), dont 42 avec urgences ou hospitalisation
Fiches remplies	88 % des jours
Répartition des grades (jours remplis)	vert 71 %, orange 22 %, rouge 6 %
Lignes éligibles à l'entraînement	8 869
Cible aggravation_7j (lignes éligibles)	1 dans 11,8 % des cas
Cible urgence_ou_hospitalisation_7j	1 dans 2,1 % des cas

Limites de cette augmentation

- Les corrélations viennent de **mes choix de simulation**, pas de la réalité. Une variable utile ici l'est parce que je l'ai reliée à l'aggravation ; une variable sans lien programmé n'apparaîtra jamais utile, même si elle l'est en vrai.
- Le fichier d'origine a des moyennes proches de 5,5 sur toutes les échelles, ce qui suggère qu'il est lui-même peu réaliste. Le jour 1 hérite de ce défaut.
- Les seuils du moteur de règles et les fréquences (aggravations, fièvres, silences) sont des choix, pas des statistiques cliniques.
- Quelques patients sont déjà en rouge dès le jour 1 (température simulée de la version précédente et symptômes élevés) et le restent plusieurs jours.

3. Utilité de chaque colonne pour la prédiction

Le modèle prédit **aggravation_7j** : le patient atteindra-t-il un grade rouge confirmé, un passage aux urgences ou une hospitalisation entre D+1 et D+7 ? Chaque colonne a un des rôles suivants :

ENTRÉE forte	ENTRÉE	CONTEXTE	TECHNIQUE	CIBLE	À EXCLURE	OPTIONNEL

Lien programmé indique si la simulation relie directement la colonne à l'aggravation. Dans la vraie vie, l'utilité réelle de chaque colonne ne pourra être jugée qu'avec de vraies données.

3.1 Onglet Patients (une ligne par patient)

Colonne	Rôle	Comment elle est produite	Utilité et précautions
id_patient	TECHNIQUE	Créé (P001 à P305)	Clé de jointure. Sert à découper entraînement/test **par patient**, pour qu'un même patient n'apparaisse jamais des deux côtés. Jamais une entrée.
id_ligne_origine	À EXCLURE	Ancien numéro de ligne	Sans signification médicale. À retirer : un modèle pourrait s'en servir à tort.
age	ENTRÉE	Réel	Le risque de complications augmente avec l'âge. Lien programmé : oui, effet modéré.
sexe	OPTIONNEL	Réel	Peu utile ici (19 hommes seulement). Sert surtout au niveau normal d'hémoglobine. Lien programmé : non.
profession	OPTIONNEL	Réel	25 valeurs pour 305 patients : bruit. À regrouper ou ignorer au début. Lien programmé : non.
fumeur, alcoolique	OPTIONNEL	Réel	Effets surtout à long terme, peu pour une alerte à 7 jours. Lien programmé : non.
niveau_AP_avant, pratique_AP, debut_AP, type_exercices	OPTIONNEL	Réel	Utiles pour l'étude sur l'activité physique, pas pour l'alerte précoce. *type_exercices* a 61 formulations et beaucoup de cases vides : à regrouper. Lien programmé : non.
duree_maladie	CONTEXTE	Réel	Contexte de gravité de la maladie. Lien programmé : non (texte « 3 ans » à convertir en nombre).
type_cancer	À EXCLURE	Réel	« Sein » pour les 305 patients : aucune information.
metastase	ENTRÉE forte	Réel	Maladie avancée donc risque plus élevé. Lien programmé : oui.
traitements	ENTRÉE forte	Réel	À découper en 4 colonnes (chimiothérapie, radiothérapie, hormonothérapie, chirurgie). La chimiothérapie est le facteur de risque principal (infections, creux du cycle). Lien programmé : oui (chimiothérapie).
technique_chir, plan_traitement	CONTEXTE	Réel	Faible pour 7 jours. Ajouter « aucune » pour les non-opérés ; fusionner « oncologie » et « oncologique ». Lien programmé : non.
date_debut_suivi	TECHNIQUE	Simulé	Permet de trier dans le temps et de couper entraînement/test par date. Pas une entrée.
hta, diabete, anemie_connue, vih	CONTEXTE	Simulé : hypertension et diabète selon l'âge, anémie 12 %, VIH 4 %	Terrain plus fragile. Lien programmé : via n_comorbidites ; l'anémie influence en plus l'hémoglobine. Les effets propres de chaque maladie ne sont pas modélisés.
n_comorbidites	ENTRÉE	Calculé (somme des 4 ci-dessus)	Résume la fragilité. Lien programmé : oui (au moins une comorbidité).
ecog_etat_general	ENTRÉE	Simulé, déduit de capacite_physique	Mesure standard de l'état général (0 normal à 3 très limité). Lien programmé : indirect (il influence les antécédents d'urgences).
ligne_traitement	CONTEXTE	Simulé, plus avancé si métastases	Plus la ligne est avancée, plus le patient est fragile. Lien programmé : indirect.
antecedent_urgences	ENTRÉE	Simulé	Un patient déjà passé aux urgences y retourne plus souvent. Lien programmé : oui.
antecedent_hospitalisation	CONTEXTE	Simulé	Utile en réel ; ici corrélé à l'autre antécédent. Lien programmé : indirect.
distance_hopital_km	OPTIONNEL	Simulé	N'influence pas l'état médical ; utile pour décider qui rappeler en priorité. Lien programmé : non.

Colonne	Rôle	Comment elle est produite	Utilité et précautions
poids_debut_kg	OPTIONNEL	Simulé	Utile surtout pour suivre une perte de poids avec des pesées régulières. Lien programmé : non.
duree_cycle_jours	CONTEXTE	Simulé (21 jours 75 %, 28 jours 15 %, 14 jours 10 %)	Définit où se situe le creux du cycle. Sert à calculer la position dans le cycle.
nb_cycles_avant_suivi	CONTEXTE	Simulé (0 à 5)	Les effets s'accumulent avec les cycles. Lien programmé : léger (hémoglobine).
statut_vital	À EXCLURE	Réel	C'est un résultat (survie), pas une information de départ. L'utiliser comme entrée reviendrait à donner la réponse au modèle.

3.2 Onglet Suivi_quotidien (une ligne par patient et par jour)

Colonne	Rôle	Comment elle est produite	Utilité et précautions
id_patient, jour_suivi	TECHNIQUE	Clés	Identifient la ligne. *jour_suivi* donne le nombre de jours depuis le début du suivi, utilisable comme variable.
date	TECHNIQUE	Simulé	Découpage chronologique. Pas une entrée.
questionnaire_rempli	ENTRÉE	Simulé	Un jour sans réponse est une information : le patient silencieux va parfois mal. On en tire le « nombre de fiches manquantes sur 7 jours ». Lien programmé : oui.
niveau_fatigue	ENTRÉE forte	Réel au jour 1 puis simulé, poids 1,1	Premier signal d'une dégradation lente : l'exemple type de tendance à repérer (pente, écart à la normale du patient).
nausee_vomissement	ENTRÉE forte	Idem, poids 1,0	Peut empêcher de boire et de prendre le traitement. Lien programmé : oui.
niveau_appetit	ENTRÉE	Idem, poids 0,9	Baisse d'appétit précoce avant l'aggravation. Lien programmé : oui.
douleurs_dyspnee_insomnies	ENTRÉE	Idem, poids 0,9	Ce score mélange trois choses. Dans l'application, il faudra les demander séparément.
niveau_diarrhees	ENTRÉE forte	Idem, poids 0,8	Risque de déshydratation. Lien programmé : oui.
niveau_constipation	ENTRÉE	Idem, poids 0,4	Signal plus faible. Utile surtout dans le score global.
capacite_physique, capacite_travail_loisirs, etat_emotionnel, capacite_sociale, capacite_cognitive	CONTEXTE	Idem, poids 0,3 à 0,6	Mesurent la qualité de vie et évoluent plus lentement. À regrouper en un « score de fonction » dont on suit la pente. Utilité réelle probablement moyenne.
chute_cheveux	OPTIONNEL	Idem, poids 0,1, dérive lente sous chimiothérapie	Quasi inutile pour une alerte à 7 jours : elle varie peu d'un jour à l'autre.
temperature_c	ENTRÉE forte	Jour 1 : version précédente ; ensuite 36,7 °C avec bruit, fièvres rares et plus probables avant une aggravation	Signal d'alerte numéro un sous chimiothérapie. On en tire la température maximale sur 3 jours et le nombre de jours de fièvre sur 7. Lien programmé : oui.
traitement_pris	ENTRÉE	Simulé (0 pendant l'hospitalisation)	Un médicament non pris révèle un problème (nausées, fatigue). Dans la simulation c'est en partie une conséquence de l'état.
jour_dans_cycle, jours_depuis_derniere_dose, nb_cycles_recus	ENTRÉE forte	Simulé pour les patients sous chimiothérapie	Le risque d'infection est maximal environ 1 à 2 semaines après la dose, quand les globules blancs sont au plus bas. Lien programmé : oui (événements plus probables au creux).
utilisation_chat	OPTIONNEL	Simulé	Plus de questions quand l'état se dégrade, mais signal faible et dépendant des habitudes du patient.
appel_infirmiere	À EXCLURE	Calculé : 70 % des jours orange, 100 % des rouges, 2 % sinon	C'est une conséquence de l'état. L'utiliser comme entrée fausserait le modèle, et l'appel peut éviter l'aggravation qu'on cherche à prédire.

Colonne	Rôle	Comment elle est produite	Utilité et précautions
globules_blancs_giga_l	ENTRÉE forte	Simulé chaque semaine (chimiothérapie), baisse au creux et avant aggravation	En réel, une baisse des globules blancs (neutropénie) rend une fièvre dangereuse. Valeur manquante la plupart des jours : garder la dernière valeur connue et le nombre de jours depuis la mesure.
hemoglobine_g_dl	ENTRÉE	Simulé chaque semaine, baisse lente avec les cycles	Anémie donc fatigue et essoufflement. Moins de lien direct avec l'aggravation à 7 jours.
grade_jour	ENTRÉE	Calculé par le moteur de règles	Résumé du jour (0, 1 ou 2). Redondant avec les symptômes, mais pratique pour construire « jours en orange sur 7 jours » ou « pire grade de la semaine ».
alerte_confirmee_infirmiere	TECHNIQUE	Calculé (85 % des rouges confirmés, 100 % les jours d'aggravation)	Sert à fabriquer la cible. Utilisable seulement pour des jours passés (ex. jours depuis le dernier rouge confirmé), jamais pour D+1 à D+7.
urgence_ou_hospitalisation	TECHNIQUE	Simulé (jour de l'événement)	Sert à fabriquer la cible. Comme ci-dessus, passé seulement.
grade_rouge_7j	CIBLE	Calculé : rouge confirmé entre D+1 et D+7	Cible intermédiaire, circulaire : le grade vient des règles, donc le modèle risque d'apprendre à retrouver les règles.
urgence_ou_hospitalisation_7j	CIBLE	Calculé	Cible la plus objective, mais rare (2 %) : peu d'exemples.
aggravation_7j	CIBLE	Calculé : l'une ou l'autre	Cible principale à prédire (11,8 % de 1 parmi les lignes éligibles).
eligible_entrainement	TECHNIQUE	Calculé	Filtre : cible connue, fiche remplie et patient pas déjà en rouge. Évite que le modèle « devine » que quelqu'un en rouge le restera demain.

4. Ce que ces données permettront (et ne permettront pas)

Dans cette simulation, les variables réellement liées à l'aggravation sont : la chimiothérapie, les métastases, l'âge, la présence d'une comorbidité, l'antécédent d'urgences, le niveau de symptômes au départ, la position dans le cycle, la montée des symptômes, la fièvre, les globules blancs et le silence du patient. Toutes les autres colonnes ne seront pas jugées utiles par un modèle, quelle que soit leur valeur réelle.

Elles permettent donc de :

- vérifier que le calcul des variables (moyennes sur 7 jours, pentes, écart à la normale du patient) fonctionne sans fuite d'information ;
- mettre au point le découpage par patient et par date, et les mesures d'évaluation adaptées à un événement rare (part des cas graves détectés plutôt que simple exactitude) ;
- construire un modèle de démonstration pour l'application.

Elles ne permettent pas de dire quelles variables comptent en vrai, ni de fixer des seuils cliniques. Pour cela, il faut remplacer les colonnes simulées par les mesures réelles du pilote, en gardant la même structure (une ligne par patient et par jour), puis faire valider les seuils par l'oncologue.